

# Résumé : Statistique 2

## Module 1

### Rappels

Quelques rappels de statistique descriptive :

- **Moyenne** :  $\bar{x} = \frac{1}{n} \sum r_i \cdot x_i$
- **Variance (Unités<sup>2</sup>)** :  $Var(x) = \overline{x^2} - \bar{x}^2 = \frac{1}{n} \cdot \sum r_i \cdot (x_i)^2 - (\bar{x})^2 = \frac{1}{n} \sum r_i \cdot (x_i - \bar{x})^2$
- **Ecart-Type** :  $\sigma(x) = \sqrt{Var(x)}$

### Estimation de paramètres

Cette partie du cours est destinée à utiliser un estimateur(échantillon) pour une information sur la population.

Un estimateur est d'autant plus efficace que sa variance est petite.

Un estimateur est **absolument correct** s'il est **sans biais** ( $E(\hat{\theta}) = \theta$ ) et **consistant** ( au plus l'échantillon de personnes interrogées grandit, au plus  $\hat{\theta}$  se rapproche de  $\theta$ ).

### Notations

Variable	Estimateur
p	f
m	$\bar{x}$
$\sigma^2$	$S_n^2$

N: taille de la population

n: taille de l'échantillon

m : moyenne pour la population

$\bar{x}$  : moyenne pour l'échantillon

p: proportion pour la population

f : fréquence pour l'échantillon

$\sigma^2$ : variance pour la population

$S_n^2$  : variance pour l'échantillon

### Non-Exhaustif

- $E(\bar{x}) = m$
- $Var(\bar{x}) = \frac{\sigma^2}{n}$
- $E(f) = p$


- $Var(f) = \frac{p(1-p)}{n}$
- $E(S_n^2) = \frac{n-1}{n} \cdot \sigma^2$
- $E(S_{n-1}^2) = \sigma^2$  ( $S_{n-1}^2 = \frac{n}{n-1} \cdot S_n^2$ )

## Exhaustif

- $E(\bar{x}) = m$
- $Var(\bar{x}) = \frac{\sigma^2}{n} \cdot \frac{N-n}{N-1}$
- $E(f) = p$
- $Var(f) = \frac{p(1-p)}{n} \cdot \frac{N-n}{N-1}$
- $E(S_n^2) = \frac{n-1}{n} \cdot \frac{N}{N-1} \cdot \sigma^2$
- $E(\frac{N-1}{N} \cdot S_{n-1}^2) = \sigma^2$


## Estimation par intervalle de confiance

On souhaite donc utiliser cet estimateur pour .... estimer (*LUL*) un paramètre. Cet estimation à un coût en termes de précision. Le but est donc de déterminer un intervalle dans lequel on estime que le paramètre à  $(1 - \alpha)$  <sup>1</sup> chances de se trouver.




$$\alpha = 0,01$$

**99 chances sur 100** que la valeur du paramètre recherché se trouve dans l'intervalle de confiance mais la **précision** autour de la valeur prédite est **faible**



$$\alpha = 0,05$$

**95 chances sur 100** que la valeur du paramètre recherché se trouve dans l'intervalle de confiance et la **précision** autour de la valeur prédite est **correcte**.



$$\alpha = 0,10$$

**90 chances sur 100** que la valeur du paramètre recherché se trouve dans l'intervalle de confiance mais la **précision** autour de la valeur prédite est **élevée**.

La zone colorée représente la **marge d'erreur tolérée**.

$$Pr\{L_i \leq \theta \leq L_s\} = 1 - \alpha$$

L'intervalle ( si  $n \cdot p > 5$  et  $n > 30$ ) vaut

<sup>1</sup> g est la valeur dans la table de gauss de  $1 - \frac{\alpha}{2}$  ( $\alpha$  de 0.05 donne un g de 1.96)

## Echantillon non exhaustif

$$[f - g \cdot \sqrt{\frac{p(1-p)}{n}}; f + g \cdot \sqrt{\frac{p(1-p)}{n}}]$$

## Echantillon exhaustif

$$\left[ f - 1.96 \cdot \sqrt{\frac{N-n}{N-1}} \cdot \sqrt{\frac{p(1-p)}{n}}; f + 1.96 \cdot \sqrt{\frac{N-n}{N-1}} \cdot \sqrt{\frac{p(1-p)}{n}} \right]$$

Remplacer f

f remplacé par 0.5 pour maximiser le risque d'erreur.

**Niveau de confiance n'existe pas dans la table**

$$a \approx g^- + \frac{a-a^-}{a^+-a^-} \cdot (g^+ - g^-) = g$$

## Intervalle de confiance d'une moyenne

---

### Grande taille (n>30)

**Non-Exhaustif**

$$\left[ \bar{x} - g \cdot \frac{\sigma}{\sqrt{n}}; \bar{x} + g \cdot \frac{\sigma}{\sqrt{n}} \right]$$

**Exhaustif**

$$\left[ \bar{x} - g \cdot \sqrt{\frac{N-n}{N-1}} \cdot \frac{\sigma}{\sqrt{n}}; \bar{x} + g \cdot \sqrt{\frac{N-n}{N-1}} \cdot \frac{\sigma}{\sqrt{n}} \right]$$

### Petite taille (n<30)

« **moyenne standardisée des échantillons** » suit une loi t de Student à (n - 1) degrés de liberté.

$$E(t_v) = 0, Var(t_v) = \frac{v}{v-2} \text{ avec } (v > 2)$$

$$v = n - 1$$

$$\text{En sachant que } E(\bar{x}) = m \text{ et } var(\bar{x}) = \frac{\sigma^2}{n}$$

On obtiens la fonction suivante

$$Pr(\bar{x}) \left\{ \bar{x} - StudentVal * \sqrt{\frac{\sigma^2}{n}} \leq E(\bar{x}) \leq \bar{x} + StudentVal * \sqrt{\frac{\sigma^2}{n}} \right\}$$

**Echantillon exhaustif**

$$Pr(\bar{x}) \left\{ \bar{x} - StudentVal * \sqrt{\frac{N-n}{N-1}} * \sqrt{\frac{\sigma^2}{n}} \leq E(\bar{x}) \leq \bar{x} + StudentVal * \sqrt{\frac{N-n}{N-1}} * \sqrt{\frac{\sigma^2}{n}} \right\}$$

## Marge d'erreur associée à un intervalle de confiance

La marge d'erreur associée à un intervalle correspond à la **demi amplitude de cet intervalle**.

De façon générale, la marge d'erreur vaut :

- Pour l'intervalle de confiance d'une proportion :  $a \cdot \sqrt{\frac{p \cdot (1-p)}{n}}$
- Pour un intervalle de confiance de moyenne :  $a \cdot \frac{\sigma}{\sqrt{n}}$

Pour diminuer cette marge d'erreur, nous pouvons soit **augmenter la taille de l'échantillon**, soit **augmenter le niveau d'incertitude**.

### Marge d'erreur Maximale

La marge d'erreur maximale est obtenue lorsque  $p = 0.5$ .