

Résumé : Statistique 2

Module 1

Rappels

Quelques rappels de statistique descriptive :

- **Moyenne** : $\bar{x} = \frac{1}{n} \sum r_i \cdot x_i$
- **Variance (Unités²)** : $Var(x) = \overline{x^2} - \bar{x}^2 = \frac{1}{n} \cdot \sum r_i \cdot (x_i)^2 - (\bar{x})^2 = \frac{1}{n} \sum r_i \cdot (x_i - \bar{x})^2$
- **Ecart-Type** : $\sigma(x) = \sqrt{Var(x)}$

Estimation de paramètres

Cette partie du cours est destinée à utiliser un estimateur(échantillon) pour une information sur la population.

Un estimateur est d'autant plus efficace que sa variance est petite.

Un estimateur est **absolument correct** s'il est **sans biais** ($E(\hat{\theta}) = \theta$) et **consistant** (au plus l'échantillon de personnes interrogées grandit, au plus $\hat{\theta}$ se rapproche de θ).

Notations

Variable	Estimateur
p	f
m	\bar{x}
σ^2	S_n^2

N: taille de la population

n: taille de l'échantillon

m : moyenne pour la population

\bar{x} : moyenne pour l'échantillon

p: proportion pour la population

f : fréquence pour l'échantillon

σ^2 : variance pour la population

S_n^2 : variance pour l'échantillon

Non-Exhaustif

- $E(\bar{x}) = m$
- $Var(\bar{x}) = \frac{\sigma^2}{n}$
- $E(f) = p$


- $Var(f) = \frac{p(1-p)}{n}$
- $E(S_n^2) = \frac{n-1}{n} \cdot \sigma^2$
- $E(S_{n-1}^2) = \sigma^2$ ($S_{n-1}^2 = \frac{n}{n-1} \cdot S_n^2$)

Exhaustif

- $E(\bar{x}) = m$
- $Var(\bar{x}) = \frac{\sigma^2}{n} \cdot \frac{N-n}{N-1}$
- $E(f) = p$
- $Var(f) = \frac{p(1-p)}{n} \cdot \frac{N-n}{N-1}$
- $E(S_n^2) = \frac{n-1}{n} \cdot \frac{N}{N-1} \cdot \sigma^2$
- $E(\frac{N-1}{N} \cdot S_{n-1}^2) = \sigma^2$

Estimation par intervalle de confiance

On souhaite donc utiliser cet estimateur pour estimer (*LUL*) un paramètre. Cet estimation à un coût en termes de précision. Le but est donc de déterminer un intervalle dans lequel on estime que le paramètre à $(1 - \alpha)$ ¹ chances de se trouver.



$$\alpha = 0,01$$

99 chances sur 100 que la valeur du paramètre recherché se trouve dans l'intervalle de confiance mais la **précision** autour de la valeur prédite est **faible**

$$\alpha = 0,05$$

95 chances sur 100 que la valeur du paramètre recherché se trouve dans l'intervalle de confiance et la **précision** autour de la valeur prédite est **correcte**.

$$\alpha = 0,10$$

90 chances sur 100 que la valeur du paramètre recherché se trouve dans l'intervalle de confiance mais la **précision** autour de la valeur prédite est **élevée**.

La zone colorée représente la **marge d'erreur tolérée**.

$$Pr\{L_i \leq \theta \leq L_s\} = 1 - \alpha$$

L'intervalle (si $n \cdot p > 5$ et $n > 30$) vaut

g est la valeur dans la table de gauss de $1 - \frac{\alpha}{2}$ (α de 0.05 donne un g de 1.96)

Echantillon non exhaustif

$$[f - g \cdot \sqrt{\frac{p(1-p)}{n}}; f + g \cdot \sqrt{\frac{p(1-p)}{n}}]$$

Echantillon exhaustif

$$[f - 1.96 \cdot \sqrt{\frac{N-n}{N-1}} \cdot \sqrt{\frac{p(1-p)}{n}}; f + 1.96 \cdot \sqrt{\frac{N-n}{N-1}} \cdot \sqrt{\frac{p(1-p)}{n}}]$$

Remplacer f

f remplacé par 0.5 pour maximiser le risque d'erreur.

Niveau de confiance n'existe pas dans la table

$$a \approx g^- + \frac{a-a^-}{a^+-a^-} \cdot (g^+ - g^-) = g$$

Intervalle de confiance d'une moyenne

Grande taille (n>30)

Non-Exhaustif

$$\left[\bar{x} - g \cdot \frac{\sigma}{\sqrt{n}}; \bar{x} + g \cdot \frac{\sigma}{\sqrt{n}} \right]$$

Exhaustif

$$\left[\bar{x} - g \cdot \sqrt{\frac{N-n}{N-1}} \cdot \frac{\sigma}{\sqrt{n}}; \bar{x} + g \cdot \sqrt{\frac{N-n}{N-1}} \cdot \frac{\sigma}{\sqrt{n}} \right]$$

Petite taille (n<30)

« **moyenne standardisée des échantillons** » suit une loi t de Student à (n - 1) degrés de liberté.

$$E(t_v) = 0, Var(t_v) = \frac{v}{v-2} \text{ avec } (v > 2)$$

$$v = n - 1$$

$$\text{En sachant que } E(\bar{x}) = m \text{ et } var(\bar{x}) = \frac{\sigma^2}{n}$$

On obtiens la fonction suivante

$$Pr(\bar{x}) \left\{ \bar{x} - StudentVal * \sqrt{\frac{\sigma^2}{n}} \leq E(\bar{x}) \leq \bar{x} + StudentVal * \sqrt{\frac{\sigma^2}{n}} \right\}$$

Echantillon exhaustif

$$Pr(\bar{x}) \left\{ \bar{x} - StudentVal * \sqrt{\frac{N-n}{N-1}} * \sqrt{\frac{\sigma^2}{n}} \leq E(\bar{x}) \leq \bar{x} + StudentVal * \sqrt{\frac{N-n}{N-1}} * \sqrt{\frac{\sigma^2}{n}} \right\}$$

Marge d'erreur associée à un intervalle de confiance

La marge d'erreur associée à un intervalle correspond à la **demi amplitude de cet intervalle**.

De façon générale, la marge d'erreur vaut :

- Pour l'intervalle de confiance d'une proportion : $a \cdot \sqrt{\frac{p \cdot (1-p)}{n}}$
- Pour un intervalle de confiance de moyenne : $a \cdot \frac{\sigma}{\sqrt{n}}$

Pour diminuer cette marge d'erreur, nous pouvons soit **augmenter la taille de l'échantillon**, soit **augmenter le niveau d'incertitude**.

Marge d'erreur Maximale

La marge d'erreur maximale est obtenue lorsque $p = 0.5$.